
Ética da Inteligência Artificial

Capítulo 2: Não-maleficência — o que devemos fazer?

Tradução e adaptação para o português: José Lucas Lira Bizil, Fernando Mazzeto Lisboa Lima e Matheus da Silva Fernandes

Programa CiberExt 26-29 · FEELT38103 · Universidade Federal de Uberlândia

Original: *Ethics of AI*, Universidade de Helsinque

2026

Sumário

Capítulo 2: Não-maleficência — o que devemos fazer?	1
I. O que devemos fazer?	1
O princípio da beneficência	1
II. O bem comum — calculando consequências	2
III. Os problemas do utilitarismo	5
IV. Bem comum e bem-estar	7
Referências	8

Capítulo 2: Não-maleficência — o que devemos fazer?

SOBRE ESTE CAPÍTULO

Eixo: Conceitos e Riscos

O que significa “fazer o bem” e “não causar dano” quando falamos de IA? Este capítulo apresenta o utilitarismo — uma das respostas filosóficas clássicas para a pergunta sobre o bem comum — e também seus limites.

I. O que devemos fazer?

O princípio da beneficência

“A IA inevitavelmente se enreda nas dimensões éticas e políticas das vocações e práticas em que está inserida. A ética da IA é, na prática, um microcosmo dos desafios políticos e éticos enfrentados pela sociedade.”

Brent Mittelstadt

O princípio da **beneficência** diz “faça o bem”, enquanto o princípio da **não-maleficência** afirma “não cause dano”. Embora esses dois princípios possam parecer semelhantes, representam princípios distintos. A beneficência incentiva a criação de uma IA benéfica (“a IA deve ser desenvolvida para o bem comum e o benefício da humanidade”), ao passo que a não-maleficência diz respeito às consequências negativas e aos riscos da IA.

De modo geral, a ética da IA tem se ocupado principalmente do princípio da não-maleficência. A discussão concentrou-se sobretudo em como desenvolvedores, fabricantes, autoridades e outras partes interessadas devem minimizar os riscos éticos — discriminação, proteção da privacidade, danos físicos e sociais — que podem surgir de aplicações de IA. Com frequência, essas discussões são formuladas em termos de uso indevido intencional, invasão maliciosa, medidas técnicas ou estratégias de gestão de risco.

O SOLUCIONISMO TECNOLÓGICO

Críticos afirmam que a ênfase na não-maleficência transforma a ética numa questão de encontrar soluções técnicas para problemas técnicos. Os problemas morais passam a ser vistos como coisas que podem ser resolvidas por “consertos” técnicos, ou apenas por um bom projeto. Esquece-se o contexto ético e social mais amplo em que os sistemas técnicos estão inseridos. Muitas questões importantes que orientam o controle, a governança e as dimensões sociais da IA são ignoradas.

O pesquisador de tecnologia Evgeny Morozov chama isso de “solucionismo tecnológico” (*tech solutionism*) — a convicção de que problemas causados pela tecnologia sempre podem ser resolvidos com mais tecnologia.

Como resultado, problemas éticos profundos e difíceis são simplificados demais e ficam sem resposta. Uma dessas questões é o problema do “bem comum”. O que exatamente isso significa? Neste capítulo, examinaremos uma resposta filosófica clássica.

II. O bem comum — calculando consequências

Ilustração. © Keksi Agency via Cidade de Helsinque / Comunicação

Suponha que você seja o diretor digital (*Chief Digital Officer*) da cidade de Helsinque. Pedem que você avalie se a organização de saúde da cidade deveria migrar de uma saúde “reativa” para uma saúde “preventiva”. Você lê um relatório. Ele fala de sistemas de aprendizado de máquina (*machine learning*) novos e sofisticados que ajudariam as autoridades de saúde a prever os possíveis riscos de saúde dos cidadãos.

Esses métodos produzem previsões combinando e analisando diversas fontes de dados médicos e de



Figura 1: Ilustração

sistemas de saúde. Analisando um grande número de critérios, indivíduos de alto risco poderiam ser identificados e priorizados. Essas pessoas poderiam ser convidadas proativamente a uma consulta médica para receber o tratamento adequado.

Os benefícios

O relatório menciona muitas vantagens. Por exemplo, a prevenção de doenças tem grande potencial de melhorar a saúde e a qualidade de vida dos cidadãos. Além disso, permitiria melhor estimativa de impacto e melhor planejamento dos serviços básicos de saúde. A saúde preventiva também tem potencial de reduzir significativamente os custos sociais e de saúde. Essas economias, enfatiza o relatório, poderiam ser usadas para o bem comum.

Os problemas potenciais

O relatório, porém, também traz algumas preocupações. Por exemplo, os sistemas levantam uma série de questões jurídicas e éticas relativas à privacidade, à segurança e ao uso dos dados. O relatório pergunta, por exemplo: onde fica a fronteira entre prevenção aceitável e intrusão inaceitável? A cidade tem direito de usar dados médicos privados e sensíveis para identificar pacientes de alto risco? Como deve ser dado o consentimento, e o que acontecerá com as pessoas que não o derem? E quanto às pessoas que não dão consentimento porque não são capazes de fazê-lo?

O relatório levanta ainda a questão fundamental do papel da cidade: se a cidade tem informação sobre um risco potencial de saúde e não age sobre esses dados, a cidade é culpada de negligência? Os cidadãos são tratados igualmente nos mundos físico e digital? Se uma pessoa desmaia na vida real, chamamos uma ambulância sem ter permissão explícita para isso. No mundo digital, preocupações com privacidade podem nos impedir de contatar os cidadãos.

O que você acha do exemplo acima? Como diretor digital, você promoveria o uso de métodos preventivos? Se sua resposta for algo como “sim, a cidade deveria buscar uma forma ética e juridicamente aceitável de usar esses métodos — há tantas vantagens em comparação com os possíveis riscos”, você provavelmente estava usando uma forma de raciocínio moral chamada “utilitarismo”.

UTILITARISMO

Utilitarismo é uma família de teorias éticas. Ela concebe “benefícios” como ações que maximizam o bem-estar de todos os indivíduos afetados. O utilitarismo é uma versão do consequencialismo, que afirma que as consequências de qualquer ação são os únicos padrões do certo e do errado.

Segundo os utilitaristas, as ações moralmente corretas são aquelas que produzem o maior saldo de benefícios sobre danos para todos os afetados. Diferentemente de outras formas mais individualistas de consequencialismo (como o egoísmo) ou de consequencialismos com pesos desiguais (como o prioritarismo), o utilitarismo considera igualmente os interesses de todos os seres humanos. Contudo, os utilitaristas divergem em muitas questões específicas, como saber se as ações devem ser escolhidas com base em seus resultados prováveis (utilitarismo de ato) ou se os agentes devem se conformar a regras que maximizem a utilidade (utilitarismo de regra). Há também divergência sobre se deve ser maximizada a utilidade total (utilitarismo total), a média (utilitarismo médio) ou a mínima.

Para os utilitaristas, a utilidade — ou benefício — é definida em termos de bem-estar ou felicidade. Por exemplo, Jeremy Bentham, o pai do utilitarismo, caracterizou a utilidade como “aquela propriedade [...] que tende a produzir benefício, vantagem, prazer, bem ou felicidade [...] ou a impedir que ocorram dano, dor, mal ou infelicidade à parte cujo interesse está sendo considerado.”

O utilitarismo oferece um método relativamente simples para decidir se uma ação é moralmente correta ou não. Para descobrir o que devemos fazer, seguimos estes passos:

- primeiro, identificamos as várias ações que poderíamos realizar;
- segundo, estimamos os benefícios e os danos que resultariam de cada ação;
- terceiro, escolhemos a ação que oferece os maiores benefícios depois de considerados os custos.

O utilitarismo fornece muitas ideias e conceitos interessantes. Por exemplo, o princípio da “utilidade marginal decrescente” é útil para diversos fins. Segundo esse princípio, a utilidade de um item diminui à medida que a oferta de unidades aumenta (e vice-versa).

Por exemplo, quando você começa a se exercitar, no início o benefício é grande e seus resultados melhoram dramaticamente. Mas quanto mais tempo você continua treinando, menor o impacto de cada sessão individual. Se você treina demais, a utilidade diminui e você começa a sofrer com os sintomas de excesso de treino.

Outro exemplo: se você come uma bala, terá bastante prazer. Mas se comer balas demais, pode ganhar peso e aumentar o risco de todo tipo de doença. Esse paradoxo dos benefícios deve ser sempre lembrado quando avaliamos as consequências das ações. O que é o bem comum agora pode não ser o bem comum no futuro.

III. Os problemas do utilitarismo

O utilitarismo não é uma explicação perfeita da tomada de decisão moral. Ele foi criticado sob muitos aspectos. Por exemplo, o cálculo utilitarista exige que atribuamos valores aos benefícios e danos resultantes de nossas ações e os comparemos com as consequências que poderiam resultar de outras ações. Mas frequentemente é difícil, senão impossível, medir e comparar antecipadamente os




Figura 2: Passado, futuro, presente

valores de todos os benefícios e custos relevantes.

“Risco” é comumente usado para significar a probabilidade de um perigo ou ameaça que surge de modo imprevisível ou, num sentido mais técnico, a probabilidade de determinado grau de dano. Na ética da IA, entende-se que danos e riscos surgem do projeto, da aplicação inadequada ou do uso indevido intencional da tecnologia. Exemplos típicos são riscos como discriminação, violação de privacidade, questões de segurança, guerra cibernética ou invasão maliciosa. Na prática, é difícil comparar riscos e benefícios pelas seguintes razões:

Primeira: riscos e benefícios são influenciados por compromissos de valor, preferências subjetivas e diversas, circunstâncias práticas e fatores pessoais e culturais.

Segunda: danos e benefícios não são estáticos. A utilidade marginal de um item diminui de um modo que pode ser difícil de prever. Além disso, um dano específico ou um benefício específico pode ter valor de utilidade diferente em circunstâncias diferentes. Por exemplo, se um carro mais rápido será ou não mais benéfico depende do uso pretendido — se a intenção é que seja um ônibus escolar, devemos priorizar a segurança; se for usado como carro de corrida, a resposta pode ser outra.

Terceira: as situações do mundo real costumam ser tão complexas que é difícil prever ou comparar antecipadamente todos os riscos e benefícios. Por exemplo, analisemos as possíveis consequências da robótica militar. Embora os robôs militares contemporâneos sejam em grande parte operados remotamente ou semiautônomos, com o tempo é provável que se tornem totalmente autônomos. Segundo algumas estimativas, os robôs reduzem as baixas civis e militares. Mas, segundo outras,




Figura 3: Utilidade marginal decrescente

eles não reduzem o risco para os civis. Estatisticamente, nas primeiras décadas de guerra do século XXI, armamentos robóticos estiveram envolvidos em numerosas mortes tanto de soldados quanto de não combatentes. A possibilidade de usar diversas técnicas — como *adversarial patches* (adesivos adversariais, que interrompem a capacidade de uma máquina de classificar imagens corretamente) — para enganar e manipular armas automatizadas complica a situação ao aumentar o risco específico de causar dano a civis. O nível geral de risco também depende da facilidade com que guerras poderiam ser declaradas caso os robôs assumam a maior parte do risco físico.

Quarta: o utilitarismo não leva em conta outros aspectos morais. É fácil imaginar situações em que uma tecnologia desenvolvida produziria grandes benefícios para as sociedades, mas cujo uso ainda assim levantaria questões éticas importantes. Por exemplo, pensemos no caso de um sistema de saúde preventiva. O sistema pode de fato ser benéfico para muitos, mas ainda nos obriga a perguntar se direitos humanos fundamentais, como a privacidade, importam. Ou o que acontece com o direito do cidadão de *não* saber sobre possíveis problemas de saúde? (Muitos de nós gostaríamos de saber se estamos num grupo de alto risco, mas e se alguém não quiser saber? Pode uma cidade impor esse conhecimento a essa pessoa?) Ou ainda: como garantir que todos tenham acesso igual aos possíveis benefícios de um sistema preventivo?

O MONSTRO DE UTILIDADE DE NOZICK

Uma das maiores dificuldades do utilitarismo é a questão da utilidade: o que ela é, afinal? Tecnicamente, utilidade é apenas uma medida (uma quantidade numérica) que descreve algum tipo de “bem” subjacente que queremos maximizar. Digamos, prazer ou bem-estar (que filósofos hedonistas afirmariam ser a mesma coisa). O prazer é, ao menos em certa medida, uma experiência subjetiva, e a utilidade, como medida, deveria transformá-lo num número comparável entre sujeitos. Essa é uma exigência elevada.

Supondo que tal medida de utilidade de fato exista, o filósofo Robert Nozick apresenta o seguinte enigma. Existe uma criatura chamada Monstro de Utilidade. Sua mente hedonista é constituída de tal forma que, dado qualquer recurso, ela obtém dele mais prazer do que qualquer outro indivíduo obteria. Ela simplesmente aprecia maçãs, carros, café, liberdade etc. mais do que qualquer outra pessoa. Isso significa que ela extrai mais utilidade dessas coisas, e se somos moralmente obrigados a maximizar a utilidade produzida pelos recursos que temos, a conclusão é clara: tudo o que temos vai para o Monstro de Utilidade. Nada para mais ninguém. Isso torna o utilitarismo indefensável? Existe algum modo de o utilitarista argumentar que o enigma proposto por Nozick não é realmente um problema?

EXERCÍCIOS DESTA SEÇÃO

O material original traz aqui um questionário interativo. As perguntas não constam do repositório de origem — ficam no banco de dados da plataforma. O exercício correspondente deve ser redigido em exercicios/capitulo02-exercicios.md.

IV. Bem comum e bem-estar

Apesar dos problemas descritos na seção anterior, os princípios do utilitarismo podem nos ajudar a considerar as consequências imediatas e as menos imediatas de nossas ações. Convém lembrar que, na vida real, definir o “bem comum” exige uma diversidade de pontos de vista.

O QUE É BEM-ESTAR?

Com frequência, o termo “bem comum” é tomado como sinônimo de “bem-estar”. Mas o que é bem-estar? As raízes da pesquisa sobre bem-estar estão na Grécia antiga, onde filósofos como Aristóteles se concentravam em como alcançar “a boa vida”. Desde então, a busca pela boa vida tem sido tema constante em diferentes disciplinas. Hoje, a pesquisa em campos como psicologia, economia e ciências sociais aborda o bem-estar em termos “das dimensões biológica, pessoal, relacional, institucional, cultural e global da vida”. Essas dimensões abrangem fatores como vitalidade física e mental, satisfação social e senso de realização e plenitude pessoal.

Os estudos sobre bem-estar podem ser divididos em três subtipos principais:

1) As teorias subjetivas. Concentram-se em questões como o modo que as pessoas se sentem ao longo da vida cotidiana, ou como uma pessoa avalia a própria vida. Esse tipo de bem-estar psicológico é frequentemente descrito como a experiência de alta satisfação com a vida, altos níveis de emoções e humores agradáveis e baixos níveis de emoções e humores negativos.

2) As teorias eudaimônicas. Consideram o bem-estar principalmente como resultado da busca de objetivos positivos. A perspectiva eudaimônica diferencia o bem-estar da satisfação do desejo. Segundo essas teorias, bem-estar e felicidade subjetiva não devem ser equiparados, porque os resultados produtores de prazer que fundamentam a felicidade subjetiva não necessariamente promovem saúde e bem-estar. Em vez disso, entende-se que o bem-estar requer componentes como autonomia, domínio do ambiente, crescimento pessoal, relações positivas com os outros, senso de propósito na vida e autoaceitação. Essas dimensões descrevem o bem-estar como uma avaliação globalmente positiva de si mesmo, a aceitação da própria história de vida e dos talentos individuais como membro de uma comunidade, a crença de que a própria vida é significativa e um senso de autodeterminação.

3) As teorias sociais. Nelas, o bem-estar é abordado em termos de fatores sociais, como integração, contribuições à vida social, coerência social e aceitação social. O bem-estar depende do grau em que um indivíduo funciona bem em seus ambientes sociais.

Hoje, muitas das abordagens do bem-estar combinam elementos de todas essas teorias. O bem-estar é visto como uma combinação complexa de aspectos psicológicos, sociais e físicos, e adota uma perspectiva de qualidade de vida como um todo.

Pesquisas como o *World Happiness Report* são exemplos dessa abordagem holística. O relatório é uma publicação anual da Rede de Soluções para o Desenvolvimento Sustentável das Nações Unidas. Contém artigos e classificações de felicidade nacional baseadas na avaliação que os respondentes fazem da própria vida, que o relatório também correlaciona com diversos fatores de vida. (Até março de 2020, a Finlândia foi classificada como o país mais feliz do mundo três vezes seguidas.)

Além disso, pesquisadores desenvolvem constantemente novas maneiras de abordar o bem-estar. Por exemplo, os grandes volumes de dados (*big data*) são hoje utilizados de muitas

formas na pesquisa sobre bem-estar. Os métodos contemporâneos incluem a análise mais avançada de dados demográficos e socioeconômicos, mas também, por exemplo, o uso de ferramentas de mineração de texto em documentos escritos — como publicações no Twitter, no Facebook ou outros dados de redes sociais —, além da análise de pegadas digitais e até de traços faciais.

A abordagem do bem comum exige que todos tenham acesso aos benefícios da IA. Isso destaca a importância de assegurar que os benefícios potenciais da IA não se acumulem de forma desigual e sejam tornados acessíveis ao maior número possível de pessoas. Além disso, a IA deve estar alinhada a valores, objetivos e normas, respeitando em grau suficiente a diversidade cultural e individual.

O bem comum não é um singular, mas um plural. Identificar as normas sociais e morais da comunidade específica em que uma IA será implantada é, portanto, obrigatório. É o único caminho para levar à sociedade os benefícios potencialmente significativos e diversos da IA e para promover, entre outras coisas, maior bem-estar e assistência social para todos.

EXERCÍCIOS DESTA SEÇÃO

O material original traz aqui dois questionários interativos. As perguntas não constam do repositório de origem. Os exercícios correspondentes devem ser redigidos em `exercicios/capitulo02-exercicios.md`.

Referências

Bentham, J. (1789). *An Introduction to the Principles of Morals and Legislation*.

Mittelstadt, B. (2019). Principles alone cannot guarantee ethical AI. *Nature Machine Intelligence*, 1, 501–507.

Morozov, E. (2013). *To Save Everything, Click Here: The Folly of Technological Solutionism*. PublicAffairs.

Nozick, R. (1974). *Anarchy, State, and Utopia*. Basic Books.

World Happiness Report. UN Sustainable Development Solutions Network. <https://worldhappiness.report/>

Material original: *Ethics of AI*, um curso online gratuito da Universidade de Helsinque. Professores responsáveis: Anna-Mari Rusanen e Jukka K. Nurminen. Demais contribuintes principais: Santeri Räisänen, Sasu Tarkoma e Saara Halmetoja. Disponível em <https://ethics-of-ai.mooc.fi/>.

Esta versão: tradução e adaptação para o português brasileiro realizada por José Lucas Lira Bizil, Fernando Mazzeto Lisboa Lima e Matheus da Silva Fernandes, no âmbito do Programa CiberExt 26-29 (FEELT38103), Universidade Federal de Uberlândia, 2026. Esta é uma obra derivada; os autores originais não a revisaram nem a endossam.

Licença: Creative Commons Atribuição-NãoComercial-Compartilhável 4.0 Internacional (CC BY-NC-SA 4.0) — <https://creativecommons.org/licenses/by-nc-sa/4.0/deed.pt-br>.