
Ética da Inteligência Artificial

Capítulo 4: Transparência — devemos saber como a IA funciona?

Tradução e adaptação para o português: José Lucas Lira Bizil, Fernando Mazzeto Lisboa Lima e Matheus da Silva Fernandes

Programa CiberExt 26-29 · FEELT38103 · Universidade Federal de Uberlândia

Original: *Ethics of AI*, Universidade de Helsinque

2026

Sumário

Capítulo 4: Transparência — devemos saber como a IA funciona?	1
I. Transparência na IA	1
O princípio da transparência	1
O que a transparência resolve	3
II. O que é transparência?	3
A transparência como propriedade de um sistema	4
A transparência como compreensibilidade	5
Estudo de caso: três visualizações do mesmo algoritmo	9
III. Transparência e os riscos da abertura	9
Referências	10

Capítulo 4: Transparência — devemos saber como a IA funciona?

SOBRE ESTE CAPÍTULO

Eixo: Conceitos e Riscos

Por que a transparência importa, o que exatamente ela significa, e por que sistemas de aprendizado de máquina são chamados de “caixas-pretas”. Veremos também que abertura demais, no contexto errado, cria riscos próprios.

I. Transparência na IA

O princípio da transparência

Imagine um sistema de reconhecimento facial chamado MYFACE. O MYFACE é usado para fins de segurança num aeroporto. Normalmente funciona perfeitamente, mas um dia começa a classificar erroneamente indivíduos como potencialmente perigosos. Como resultado, várias pessoas inocentes são presas. Seria importante saber por que o sistema cometeu todos esses erros? Deveríamos ser capazes de explicar por que ele errou? E por que isso importaria?




Figura 1: MYFACE

Alguns sistemas contemporâneos de aprendizado de máquina (*machine learning*) são os chamados sistemas “caixa-preta” (*black box*), o que significa que não conseguimos ver de fato como funcionam. Essa “opacidade”, ou falta de visibilidade, pode ser um problema se usamos esses sistemas para tomar decisões que afetam indivíduos.

As pessoas têm o direito de saber como decisões críticas — quem tem um pedido de empréstimo aprovado, quem obtém liberdade condicional, quem é contratado — são tomadas. Isso levou muitos

a pedir uma “IA mais transparente”.

O que a transparência resolve

Transparência é uma propriedade de um sistema que torna possível obter certa informação sobre seu funcionamento interno. Mas que informação é essa, e se ela é eticamente relevante, depende em grande medida da questão ética que estamos tentando responder. A transparência em si é eticamente neutra e não é um conceito ético. Ela constitui, antes, um ideal. É algo que pode se manifestar de muitas maneiras diferentes e que pode apresentar uma solução para questões éticas subjacentes. Nesse sentido, a transparência é relevante ao menos para as três questões seguintes:

1) A justificação das decisões. A boa governança nos setores público ou privado envolve a não arbitrariedade das decisões. Isso se aplica a qualquer tipo de tomada de decisão que tenha efeito ética ou juridicamente relevante sobre indivíduos. Não arbitrariedade significa acesso a justificativas sobre “por que essa decisão foi tomada, e com base em quê?”. Além disso, especialmente no caso da governança pública, a capacidade de contestar e recorrer é crucial. Isso representa uma exigência de reparar erros.

2) O direito de saber. Segundo os direitos humanos, as pessoas têm direito a explicações sobre como as decisões foram tomadas, de modo a manter agência, liberdade e privacidade genuínas (para mais sobre direitos humanos, veja o capítulo 5). A liberdade implica o direito de obter respostas a perguntas como: “Como estou sendo rastreado? Que tipo de inferências estão sendo feitas sobre mim? E como, exatamente, essas inferências foram feitas?”

3) Uma obrigação moral de compreender as consequências de nossas ações. Como comunidade, também temos responsabilidade pela gestão de riscos. Existe uma obrigação moral, até certo nível razoável, de compreender e prever as consequências dos tipos de tecnologia que trazemos ao mundo. Ou seja, dizer “não temos como entender agora o que isso vai fazer” não é argumento válido para liberar um sistema que causa dano. Ao contrário, é nosso dever moral explorar os riscos possíveis.

Esses três pontos podem ser resumidos como demandas por informação suficiente. Sabemos se, e em que medida, esta decisão algorítmica é justificada? Sei como as inferências sobre mim são feitas? Em que medida sou responsável pelas ações do sistema, e quanto eu deveria saber sobre seu funcionamento interno para poder assumir essa responsabilidade?

II. O que é transparência?

A transparência pode ser definida de múltiplas maneiras. Há uma série de conceitos vizinhos por vezes usados como sinônimos — entre eles “explicabilidade” (a pesquisa em IA nessa área é conhecida como “XAI”), “interpretabilidade”, “compreensibilidade” e “caixa-preta”.

A transparência é, grosso modo, uma propriedade de uma aplicação. Diz respeito a quanto é possível compreender do funcionamento interno de um sistema “em tese”. Também pode significar a maneira de fornecer explicações sobre modelos e decisões algorítmicas que sejam compreensíveis para o usuário. Isso trata da percepção e da compreensão públicas de como a IA funciona. A transparência pode ainda ser entendida como um ideal sociotécnico e normativo mais amplo de “abertura”.

Há muitas questões em aberto sobre o que constitui transparência ou explicabilidade, e sobre qual nível de transparência é suficiente para diferentes partes interessadas. Dependendo da situação, o

significado preciso de “transparência” pode variar. É uma questão científica em aberto se existem vários tipos distintos de transparência. Além disso, a transparência pode se referir a coisas diferentes conforme o objetivo seja, digamos, analisar a relevância jurídica de vieses injustos (*bias*) ou discuti-los em termos de características de sistemas de aprendizado de máquina.

A transparência como propriedade de um sistema

Como propriedade de um sistema, a transparência trata de como um modelo funciona internamente. Ela se subdivide ainda em “simulabilidade” (compreensão do funcionamento do modelo), “decomponibilidade” (compreensão dos componentes individuais) e transparência algorítmica (visibilidade dos algoritmos).

O QUE FAZ DE UM SISTEMA UMA CAIXA-PRETA?

Complexidade. Nos sistemas de IA contemporâneos, a operação de uma rede neural é codificada em milhares, ou mesmo milhões, de coeficientes numéricos. Normalmente o sistema aprende seus valores na fase de treinamento. Como a operação da rede depende das interações complicadas entre esses valores, é praticamente impossível compreender como a rede funciona mesmo que todos os parâmetros sejam conhecidos.

Dificuldade de desenvolver soluções explicáveis. Mesmo que os modelos de IA utilizados suportem algum nível de explicabilidade, é necessário desenvolvimento adicional para construí-la no sistema. Pode ser difícil criar uma experiência de usuário com explicações cuidadosas e ao mesmo tempo facilmente compreensíveis.

Preocupações com risco. Muitos algoritmos de IA podem ser enganados se um atacante projetar cuidadosamente uma entrada que faça o sistema funcionar mal. Num sistema muito transparente, pode ser mais fácil burlá-lo para produzir resultados estranhos ou indesejados. Assim, às vezes os sistemas são projetados intencionalmente como caixas-pretas.

Dado que muitos dos modelos de aprendizado profundo (*deep learning*) atuais mais eficientes são modelos caixa-preta (quase por definição), os pesquisadores parecem supor ser altamente improvável que consigamos desenvolvê-los como plenamente transparentes. Por isso, a discussão se concentra em encontrar o “nível suficiente de transparência”. Bastaria que os algoritmos oferecessem às pessoas uma divulgação de como chegaram à sua decisão e apresentassem a menor mudança capaz de obter um resultado desejável (Wachter et al., 2018)? Por exemplo, se um algoritmo nega um benefício social a alguém, deveria informar a razão à pessoa e também o que ela pode fazer para reverter a decisão.

A explicação deveria informar, por exemplo, qual é o valor máximo de salário para aprovação (entrada) e como a diminuição desse valor impactaria as decisões tomadas (manipulação da entrada). Mas o problema é que o direito de saber também se aplica a situações em que o sistema comete erros. Nesse caso, pode ser necessário realizar uma autópsia no algoritmo e identificar os fatores que o levaram a errar (Rusanen & Ylikoski, 2017). Isso não pode ser feito apenas manipulando entradas e saídas.

Esta ilustração retrata um modelo de IA muito simplificado, encarregado de reconhecer todos os gatos em dados compostos por animais de todo tipo. O modelo inferiu dois padrões que compõem




Figura 2: Autópsia de um modelo

um gato. Para o modelo, são apenas números; para nós, parecem padrões descritíveis. Contudo, os padrões e características inferidos podem parecer bastante complicados para nós. Para mais informações, veja <https://distill.pub/2017/feature-visualization/>.

Além disso, a transparência cumpre muitas outras funções nos debates contemporâneos sobre modelos de aprendizado de máquina. Pode ser relevante para o desenvolvimento de legislação ou para assegurar a confiança pública na IA. Para lidar com essas questões, a noção de transparência em IA costuma receber uma definição mais ampla, em termos de “compreensibilidade”.

A transparência como compreensibilidade

A compreensibilidade de um algoritmo exige que se explique como uma decisão foi tomada por um modelo de IA de maneira suficientemente compreensível para os afetados por ele. É preciso ter uma noção concreta de como ou por que determinada decisão foi alcançada a partir das entradas.

No entanto, é notoriamente difícil traduzir conceitos derivados algoritmicamente em conceitos compreensíveis por humanos. Em alguns países, legisladores discutiram se as autoridades públicas deveriam publicar os algoritmos que usam em decisões automatizadas na forma de código de programação. Contudo, a maioria das pessoas não sabe interpretar código. É difícil, portanto, ver como a transparência aumentaria com a publicação de códigos.

```
* Toma o número da semente a partir do relógio da máquina;
data _NULL_;
seedNumber= int(%sysfunc(TIME())) ;
```

```

call symput('seedNumber',seedNumber);
run;
%put &seedNumber;

* Ordena o universo;
proc sort data=universe;
  by henro;
run;
* Cria uma amostra, n=2000;
proc surveyselect data=universe method=srs
  n=2000 seed=&seedNumber
  out=sample;
run;
* Ordena a amostra;
proc sort data=sample;
  by henro;
run;

* Une a amostra ao universo e cria a variável TYPE;
data all;
  merge universe(in=a)
        sample(in=b);
  by henro;
  length TYPE $ 1.;
  if a then TYPE='V'; * grupo de referência;
  if b then TYPE='K'; * grupo experimental;

* atribui valores à variável REAOH;
REAOH='PUOTOS';
run;

* Confirma que todas as 2000 pessoas têm TYPE com valor 'K';
proc freq;
  tables type;
run;


```

Seria mais útil publicar os algoritmos exatos? Na maioria dos casos, publicar os algoritmos exatos também não traz muita transparência, especialmente se não se tem acesso aos dados usados no modelo.

$$Q^{new}(s_t, a_t) \leftarrow \underbrace{Q(s_t, a_t)}_{\text{old value}} + \underbrace{\alpha}_{\text{learning rate}} \cdot \underbrace{\left(\underbrace{r_t}_{\text{reward}} + \underbrace{\gamma}_{\text{discount factor}} \cdot \underbrace{\max_a Q(s_{t+1}, a)}_{\text{estimate of optimal future value}} - \underbrace{Q(s_t, a_t)}_{\text{old value}} \right)}_{\text{new value (temporal difference target)}}$$

Figura 3: Aprendizado por reforço (Q-learning)

Atualmente, cientistas cognitivos e da computação desenvolvem descrições interpretáveis por humanos sobre como as aplicações se comportam e por quê. As abordagens incluem, por exemplo, o desenvolvimento de ferramentas de visualização de dados, interfaces interativas, explicações verbais ou descrições em metanível das características dos modelos. Essas ferramentas podem ser extremamente úteis para tornar as aplicações de IA mais acessíveis. Ainda assim, há muito trabalho a ser feito.



The cube of activations that a neural network for computer vision develops at each hidden layer. Different slices of the cube allow us to target the activations of individual neurons, spatial positions, or channels.

Figura 4: Exemplo do Distill

Diagrama CC BY 4.0 Olah et al., “The Building Blocks of Interpretability”, Distill, 2018.

O fato de a compreensibilidade se apoiar em componentes dependentes do sujeito e da cultura complica ainda mais o quadro. Por exemplo, a lógica de como visualizações são interpretadas — ou de como inferências são feitas a partir delas — varia entre culturas. Assim, desenvolvedores devem prestar atenção à compreensão suficiente da linguagem visual que empregam.

Além disso, muito depende do grau de letramento em dados ou algoritmos, por exemplo do conhecimento das tecnologias contemporâneas. Em algumas culturas, o vocabulário da tecnologia atual é mais familiar; em muitas outras, pode ser completamente novo. Para aumentar a compreensibilidade, há uma necessidade clara de esforços educacionais significativos na melhoria do letramento algorítmico — por exemplo, em “pensamento computacional” (Heintz et al., 2016). Esse letramento do usuário terá efeito direto sobre a transparência, no sentido da compreensão básica que os usuários comuns têm dos sistemas de IA. Pode ser, na prática, o modo mais eficiente e concreto de tornar as caixas menos pretas para muita gente.

COMO TORNAR MODELOS MAIS TRANSPARENTES?

O problema da caixa-preta da inteligência artificial não é novo. Prover transparência a modelos de aprendizado de máquina é uma área ativa de pesquisa. Grosso modo, há cinco abordagens principais:

- **Usar modelos mais simples.** Isso, porém, com frequência sacrifica acurácia em troca de explicabilidade.
- **Combinar modelos simples e sofisticados.** Enquanto o modelo sofisticado permite ao sistema realizar cálculos mais complexos, o modelo simples pode ser usado para prover transparência.
- **Modificar as entradas para rastrear dependências relevantes entre entradas e saídas.** Se a manipulação das entradas altera os resultados gerais do modelo, essas entradas podem ter papel na classificação.
- **Projetar os modelos para o usuário.** Isso requer usar métodos e ferramentas cognitivas e psicologicamente eficientes para visualizar os estados do modelo ou dirigir a atenção. Por exemplo, em visão computacional, estados em camadas intermediárias dos modelos podem ser visualizados como características (cabeças, braços, pernas), oferecendo uma descrição compreensível para a classificação de imagens. Pesquisadores também desenvolveram métodos para dirigir a “atenção” às partes da entrada que mais importam. Elas podem ser visualizadas para destacar as partes de uma imagem ou de um texto (os chamados “pesos”) que mais contribuem para determinada recomendação.
- **Acompanhar a pesquisa mais recente.** Há muita pesquisa em curso sobre diversos aspectos da IA explicável — incluindo as dimensões sociocognitivas — e novas técnicas vêm sendo desenvolvidas.

EXERCÍCIOS DESTA SEÇÃO

O material original traz aqui um questionário interativo. As perguntas não constam do repositório de origem — ficam no banco de dados da plataforma. O exercício correspondente deve ser redigido em [exercicios/capitulo04-exercicios.md](#).

Estudo de caso: três visualizações do mesmo algoritmo

QUAL DELAS É COMPREENSÍVEL?

Há necessidade de traduzir conceitos algorítmicos para a linguagem cotidiana. A maioria das pessoas sem formação em computação não conhece o vocabulário básico da IA, o que afeta diretamente sua capacidade de compreender os desenvolvimentos recentes.

- 1.
- 2.
- 3.

Compare estas três visualizações de algoritmos de aprendizado por reforço. Qual delas é a mais compreensível? Por quê?

III. Transparência e os riscos da abertura

A transparência frequentemente denota um “ideal” ético, social e jurídico moderno (Koivisto, 2016), uma exigência normativa para o uso aceitável da tecnologia em nossas sociedades. É um re-

flexo do ideal de “abertura”, formulado em termos de “governo aberto”, “dados abertos”, “código aberto/acesso aberto”, bem como “ciência aberta” (Larsson, 2020). Nesse sentido, considerações sobre transparência são necessárias para favorecer a distribuição equitativa dos avanços científicos, de modo que os benefícios do desenvolvimento da IA possam ser acessíveis a todas as pessoas.

O PARADOXO DA ABERTURA

Paradoxalmente, o ideal de abertura também pode levar a consequências danosas. Por exemplo, a transparência das plataformas de redes sociais levou a diversos casos de uso indevido e a desafios democráticos. A transparência pode criar riscos de segurança. Transparência demais pode levar ao vazamento de dados sensíveis à privacidade para as mãos erradas. Ou ainda: quanto mais se revela sobre os algoritmos e os dados, mais dano um ator malicioso pode causar. Algoritmos podem ser invadidos, e a informação pode tornar a IA mais vulnerável a ataques intencionais. Algoritmos inteiros também podem ser roubados apenas a partir de suas explicações.

Em resumo, embora haja necessidade de desenvolver práticas mais transparentes para a IA, também é preciso desenvolver práticas que ajudem a evitar abusos. Ainda que a transparência possa ajudar a mitigar questões éticas — como equidade ou responsabilização (*accountability*) —, ela também cria riscos eticamente importantes. Abertura demais no contexto errado pode frustrar o desenvolvimento positivo de processos habilitados por IA. Em conjunto, fica claro que o ideal de transparência total dos algoritmos deve ser considerado com cuidado, e será preciso encontrar um equilíbrio entre as exigências de segurança e as de transparência.

EXERCÍCIOS DESTA SEÇÃO

O material original traz aqui um questionário interativo. As perguntas não constam do repositório de origem. O exercício correspondente deve ser redigido em [exercicios/capitulo04-exercicios.md](#).

Referências

- Heintz, F., Mannila, L., & Färnqvist, T. (2016). A review of models for introducing computational thinking, computer science and computing in K-12 education. *IEEE Frontiers in Education Conference*. <https://ieeexplore.ieee.org/document/7757410>
- Koivisto, I. (2016). The anatomy of transparency: The concept and its multifarious implications.
- Larsson, S. (2020). On the governance of artificial intelligence through ethics guidelines.
- Olah, C., et al. (2018). The Building Blocks of Interpretability. *Distill*. <https://distill.pub/2018/building-blocks/>
- Rusanen, A.-M., & Ylikoski, P. (2017).
- Wachter, S., Mittelstadt, B., & Russell, C. (2018). Counterfactual Explanations Without Opening the Black Box: Automated Decisions and the GDPR. <https://arxiv.org/pdf/1811.01439.pdf>

Material original: *Ethics of AI*, um curso online gratuito da Universidade de Helsinque. Professores responsáveis: Anna-Mari Rusanen e Jukka K. Nurminen. Demais contribuintes principais: Santeri Räsänen, Sasu Tarkoma e Saara Halmetoja. Disponível em <https://ethics-of-ai.mooc.fi/>.

Esta versão: tradução e adaptação para o português brasileiro realizada por José Lucas Lira Bizil, Fernando Mazzeto Lisboa Lima e Matheus da Silva Fernandes, no âmbito do Programa CiberExt 26-29 (FEELT38103), Universidade Federal de Uberlândia, 2026. Esta é uma obra derivada; os autores originais não a revisaram nem a endossam.

Licença: Creative Commons Atribuição-NãoComercial-Compartilhagual 4.0 Internacional (CC BY-NC-SA 4.0) — <https://creativecommons.org/licenses/by-nc-sa/4.0/deed.pt-br>.