
Ética da Inteligência Artificial

Capítulo 6: Equidade — a IA deve ser justa e não discriminatória?

Tradução e adaptação para o português: José Lucas Lira Bizil, Fernando Mazzeto Lisboa Lima e Matheus da Silva Fernandes

Programa CiberExt 26-29 · FEELT38103 · Universidade Federal de Uberlândia

Original: *Ethics of AI*, Universidade de Helsinque

2026

Sumário

Capítulo 6: Equidade — a IA deve ser justa e não discriminatória?	1
I. O que é justiça?	1
Justiça e viés	2
II. As variedades da justiça	3
III. Discriminação e vieses	3
Os danos — o que são?	9
Como o viés surge?	10
IV. Removendo o viés	12
Referências	14

Capítulo 6: Equidade — a IA deve ser justa e não discriminatória?

SOBRE ESTE CAPÍTULO

Eixo: Conceitos, Aplicações e Riscos

O que é justiça? O que distingue igualdade de equidade? Quando uma diferença de tratamento se torna discriminação? Este capítulo examina os danos alocativos e representacionais, as três origens do viés (*bias*) e por que ser justo não é o mesmo que ser ético.

I. O que é justiça?

EXPERIMENTO MENTAL: O ALGORITMO DAS NOTAS

Para este experimento mental, suponhamos que, por causa da pandemia de covid-19, todos os exames de conclusão do ensino médio finlandês tenham sido cancelados. Em lugar do exame, seria preciso projetar e implementar um método alternativo para determinar as notas de qualificação atribuídas aos estudantes naquele ano. Como os estudantes são admitidos na universidade com base em suas notas, as notas desses exames são extremamente importantes. O governo decidiu que os professores dariam uma estimativa de como achavam que seus alunos teriam se saído nos exames, e que isso determinaria as notas. Pediu-se aos professores que fizessem avaliações de seus alunos.

Para combater a inflação de notas, foi usado um algoritmo que ponderava as pontuações com base no desempenho histórico de cada escola. A ideia era que o algoritmo compensasse a tendência dos professores a inflar o desempenho esperado de seus alunos e que, assim, as estimativas previssem com mais exatidão como os examinandos teriam de fato se saído. O algoritmo foi projetado com duas informações: a posição do aluno dentro da escola e o desempenho histórico da escola.

Como resultado, em nível nacional as notas corresponderam razoavelmente bem à distribuição de notas dos anos anteriores. No entanto, o algoritmo rebaixou quase 40% das notas previstas pelos professores. Os dados mostraram que os resultados de estudantes de origem socioeconômica mais baixa foram rebaixados com mais frequência do que os de origem socioeconômica mais alta. Para estudantes de baixa renda que esperavam ir para a universidade, os resultados foram devastadores.

Muitos tomariam este experimento mental como exemplo de injustiça algorítmica. Ele não descreve apenas como algoritmos podem, por si, produzir resultados injustos, mas também como podem reforçar vieses econômicos e sociais já existentes.

Justiça e viés

Justiça e viés são provavelmente as questões éticas mais discutidas em relação aos algoritmos contemporâneos. Por que são tão centrais?

- **Primeiro**, a justiça é elemento fundamental da estabilidade social. Como observa o filósofo John Rawls, a estabilidade de uma sociedade — ou de qualquer grupo — depende da medida em que seus membros sentem que estão sendo tratados de maneira justa. Quando alguns membros sentem que são tratados de modo injusto, isso costuma criar a base para inquietação social, distúrbios e conflito. As pessoas mantêm a unidade social apenas na medida em que suas instituições são justas.
- **Segundo**, como observou Immanuel Kant, os seres humanos têm a mesma dignidade. Em virtude dessa dignidade, têm direito a ser tratados como iguais. Se indivíduos são tratados injustamente — especialmente por motivos arbitrários —, sua dignidade humana fundamental é violada. Quando essa violação se efetiva em práticas, leva à discriminação.

Contudo, como ilustra o exemplo do algoritmo de inflação de notas, a justiça é uma questão complexa.

O algoritmo foi projetado para corrigir a inflação de notas porque se julgava injusto que estudantes obtivessem vantagem indevida. Como resultado, paradoxalmente, o algoritmo acabou reforçando vieses sociais já existentes.

Neste capítulo, vamos nos concentrar em justiça, vieses e discriminação. Abordaremos questões como: o que exatamente é justiça? A justiça deve consistir em assegurar que todos tenham probabilidade igual de obter algum benefício? Ou deve levar em conta as diferenças individuais e reconhecer a diversidade? E, por fim: justiça e discriminação são sinônimos, ou significam coisas distintas?

II. As variedades da justiça

Filósofos propuseram várias definições para o conceito de justiça. Segundo Aristóteles, “os iguais devem ser tratados igualmente, e os desiguais, desigualmente”.

Esse **princípio da igualdade** afirma que os indivíduos devem ser tratados da mesma forma, a menos que difiram de maneiras relevantes para a situação em que estão envolvidos.

Por exemplo, se Alan Turing e Ada Lovelace obtiveram as mesmas notas nos exames e não há diferenças relevantes entre eles ou entre os exames que prestaram, então devem receber a mesma nota. E se Turing recebesse nota melhor do que Lovelace simplesmente por ter status socioeconômico mais alto, isso seria injusto. Por quê? Porque o status socioeconômico não deveria ser relevante na atribuição de notas.

Contudo, o princípio da igualdade foi criticado por ser “cego”. Ele não leva em conta que nem todos partimos da mesma posição, nem que existem diferenças individuais que importam. Em contraste com a igualdade, a “equidade” não promove justiça tratando categoricamente todos do mesmo modo, e sim dando a todos acesso igual às mesmas oportunidades. Há situações, por exemplo, em que a diferença de origem socioeconômica é critério relevante para tratar as pessoas de modo distinto. A maioria das pessoas considerou justo, por exemplo, que o governo conceda benefícios sociais apenas aos cidadãos que realmente precisam, e não a todos.

Igualdade significa que todos são tratados da mesma forma.

Equidade significa que cada um recebe o que precisa para ter sucesso.

Por outro lado, há também critérios que não são fundamentos justificáveis para tratar pessoas de modo diferente. Em geral, consideramos injusto dar tratamento especial a indivíduos com base em idade, sexo, raça ou preferências religiosas. Em outras palavras: o que é discriminação?

TIPOS DE JUSTIÇA

Justiça distributiva é a medida em que as instituições da sociedade asseguram que benefícios e ônus sejam distribuídos entre seus membros de maneira justa.

Justiça retributiva é a medida em que as punições são justas. Em geral, as punições são consideradas justas na medida em que levam em conta critérios relevantes, como a gravidade do crime e a intenção do criminoso, e descartam critérios irrelevantes, como a raça.

Justiça compensatória é a medida em que as pessoas são justamente compensadas por seus danos por aqueles que as prejudicaram; a compensação justa é proporcional à perda infligida. É precisamente esse tipo de justiça que está em jogo nos debates sobre danos à saúde de



Figura 1: Igualdade



Figura 2: Equidade

trabalhadores em minas de carvão. Alguns argumentam que os donos das minas deveriam compensar os trabalhadores cuja saúde foi arruinada. Outros argumentam que os trabalhadores assumiram voluntariamente esse risco ao escolher o emprego nas minas.

III. Discriminação e vieses

Nesta seção estudaremos a discriminação e o modo como práticas discriminatórias podem se manifestar por meio da inteligência artificial. O viés tornou-se recentemente a questão prototípica da ética da IA, já que a esperança de que a formalidade exata dos algoritmos os tornasse imunes à parcialidade revelou-se dolorosamente falsa. Primeiro, veremos três exemplos de sistemas algorítmicos que nos ajudarão a analisar discriminação e viés em IA.

Exemplo 1: *word embeddings* (Bolukbasi et al.) Vetores de palavras (*word embeddings*) são uma forma de estrutura de dados usada em aplicações de processamento de linguagem natural (IA capaz de compreender uma língua, como o inglês). São produzidos vasculhando textos e registrando quais palavras ocorrem juntas com frequência. As associações produzidas funcionam como uma espécie de dicionário para sistemas de IA, capturando relações semânticas do tipo “homem” está para “rei” assim como “mulher” está para “rainha”. Bolukbasi et al. constataram que, sem grande surpresa, esse tipo de associação tende a codificar relações conceituais culturalmente disseminadas, mas consideradas discriminatórias. Por exemplo: “mãe” está para “enfermeira” assim como “pai” está para “médico”.

Exemplo 2: o algoritmo de recrutamento da Amazon (Dastin, 2018) Em 2014, a Amazon começou a desenvolver um sistema interno de IA para agilizar seu processo de recrutamento. Usando os currículos de candidatos anteriores como dados de treinamento, o sistema analisaria os currículos recebidos e classificaria os candidatos para avaliação posterior. Muito rapidamente, porém, descobriu-se que o sistema classificava candidatos a vagas técnicas de maneira enviesada por gênero.

Constatou-se que o sistema penalizava currículos que indicassem que a candidata era mulher. Isso incluía menções a coisas como participação em um clube feminino de xadrez ou formação numa faculdade exclusivamente feminina. Segundo relatos, a Amazon tentou remover o viés do sistema, mas acabou descartando o projeto inteiro. O sistema nunca foi usado em processos reais de recrutamento.

Exemplo 3: pontuação de crédito (Rutkenstein & Velkova, 2019) Em 2018, o tribunal finlandês de não discriminação e igualdade julgou um caso em que uma solicitação de crédito ao consumidor foi negada automaticamente por métodos estatísticos. A instituição de crédito Svea Ekonomi avaliou automaticamente a capacidade de crédito de um indivíduo no âmbito de sua compra online de materiais de construção, para a qual ele buscava crédito. A decisão foi contestada, e o tribunal concluiu que “a idade do solicitante, seu gênero masculino, o finlandês como língua materna e a residência em área rural foram todos fatores que contribuíram para um caso de discriminações múltiplas, resultando na decisão de não conceder o empréstimo.” O tribunal observou que, se o solicitante fosse mulher ou falante de sueco, o crédito teria sido concedido.




Figura 3: Viés em vetores de palavras

O que é discriminação? Primeiro, é importante notar que a palavra discriminação pode ser usada num sentido moralmente neutro (“você consegue discriminar entre estas duas cores?”). Ao longo desta seção, referimo-nos ao sentido moralmente carregado do termo. Mas quando a discriminação é moralmente suspeita? Pode parecer uma pergunta boba. Afinal, a maioria concordaria que temos um senso intuitivo bastante claro do que seja discriminação. Ao ouvir o exemplo dos vetores de palavras acima, não temos dificuldade em apontar a associação ofensiva e declarar: “isto é discriminatório!” Colocar em palavras o que a torna discriminatória, contudo, revela-se uma tarefa escorregadia. Começamos, então, escrevendo nossas intuições, e vejamos aonde isso leva:

DEFINIÇÃO 1: DISCRIMINAÇÃO

Discriminação é uma diferença de tratamento de indivíduos com base em sua pertença a um grupo.

Como essa definição se sai ao capturar nosso senso de discriminação? As palavras que fazem o trabalho aqui são “diferença” e “grupo”. Ou seja, a discriminação é algo comparativo, e as unidades de comparação são grupos diferentes (ou, antes, agrupamentos), ou indivíduos que pertencem a eles. É um bom começo, mas analisemos onde essa definição traça a linha. O que fica dentro e o que fica de fora?

Considere, por exemplo, as carteiras de motorista. Na Finlândia, elas são emitidas pela polícia mediante a conclusão de certa carga de treinamento prático e teórico, além de um exame. Assim, as carteiras são emitidas com base no mérito individual. Ainda assim, em geral achamos sensato que pessoas com deficiência visual severa sejam excluídas do processo por completo, e não consideramos isso discriminatório no sentido moral. Afinal, dirigir seria praticamente impossível de qualquer modo. Precisamos, portanto, incluir algum sentido de nocividade em nossa definição.

Considere, então, um café que só atende pessoas de camisa verde. Isso é definitivamente tratamento diferenciado com base em pertencimento a um grupo, e conduz a algum tipo de prejuízo, mas também não considerariamos isso discriminação em sentido moral. Poderíamos achar a política estranha, mas não moralmente problemática. Assim, não é apenas o pertencimento a um grupo que nos interessa, mas *quais* grupos.

DEFINIÇÃO 2: DISCRIMINAÇÃO

Discriminação é tratamento diferenciado com base em pertencimento percebido a um grupo socialmente saliente, que causa dano social (Lippert-Rasmussen, 2014).

A “saliência social” é o que identifica quais características são moralmente relevantes em casos de discriminação. Mas o que isso significa? Segundo Lippert-Rasmussen, uma característica é socialmente saliente se for importante para a estrutura das interações sociais em múltiplos contextos. Ou seja, o que se considera classificação socialmente saliente é uma questão historicamente contingente: numa linha temporal alternativa, em que usar camisa verde fosse invariavelmente questão de importância social, influenciando no tipo de dignidade, oportunidades ou status conferidos a uma pessoa (se fosse vestimenta religiosa, por exemplo), o caso do café acima poderia perfeitamente contar como discriminação.

Reconhecer a discriminação em sentido moral não é, portanto, simplesmente reconhecer discrepâncias de tratamento entre agrupamentos arbitrários. Exige, antes, contextualizar o tratamento desigual na história das práticas opressivas ou valorativas da sociedade e nos agrupamentos que ela torna salientes. Por exemplo, a Carta dos Direitos Fundamentais da União Europeia lista as seguintes características como moralmente pertinentes em casos de discriminação: sexo, raça, cor, origem étnica ou social, características genéticas, língua, religião ou convicções, opiniões políticas ou outras, pertença a uma minoria nacional, propriedade, nascimento, deficiência, idade e orientação sexual.

Os danos — o que são?

Refletindo sobre os dois exemplos acima, a condição de saliência social está claramente satisfeita em ambos. Gênero é uma categoria que historicamente sempre estruturou a interação social. E quanto ao dano? Um caso é mais claro que o outro: perder uma oportunidade de emprego por razões alheias à adequação ao cargo é claramente um dano. No caso dos vetores de palavras, qualquer dano que ocorra é mais difícil de localizar. Ao menos, não conseguimos apontar diretamente uma oportunidade perdida, um serviço recusado ou um bem negado. Ainda assim, em casos assim um dano é instaurado. Para captá-lo, precisamos compreender a diferença entre danos **alocativos** e **representacionais**, como apresentados em [Crawford, 2017](#).

Danos alocativos Danos alocativos são situações em que um indivíduo fica em pior situação quanto aos recursos disponíveis para ele. Aqui, “recursos” devem ser entendidos amplamente: não apenas comida, carros, celulares e outros bens materiais, mas também os serviços e as oportunidades oferecidos. Um salário menor pelo mesmo trabalho é definitivamente um dano alocativo. Mas também o é negar a oportunidade de uma entrevista de emprego com base no gênero, ou negar crédito com base nele.

Até abstrações como o risco podem ser objeto de danos alocativos. [Wilson, Hoffman e Morgenstern \(2019\)](#) constataram que algoritmos de detecção de objetos são piores em reconhecer figuras de tom de pele escuro do que de tom claro. As pesquisadoras Joy Buolamwini e Timnit Gebru também mostraram que algoritmos de reconhecimento facial são notavelmente piores em reconhecer rostos de pessoas racializadas ([Buolamwini e Gebru, 2018](#)). Isso significa que carros autônomos podem ter mais probabilidade de atropelar uma pessoa negra do que uma branca. Ora, dado que causar dano corporal é claramente um dano, pode-se argumentar que um dano já ocorreu mesmo antes de tais acidentes acontecerem: a distribuição desigual do risco é, ela própria, um dano alocativo à parte prejudicada.

Danos representacionais Danos representacionais são aqueles que não dizem respeito à distribuição de bens, e sim à representação de grupos e indivíduos. Essa classe inclui danos como denegrição, estereotipagem, falha de reconhecimento (*misrecognition*) e *exnominação*. Exnominação é um termo originado dos estudos de mídia e designa a prática pela qual certa categoria ou modo de ser é enquadrado como norma por não receber nome, ou por não ser especificado como categoria em si (por exemplo, “atleta” vs. “atleta feminina”).

Danos representacionais afetam as narrativas que construímos sobre os grupos sociais relevantes. Ao amplificar visões estereotipadas, degradar o status social de indivíduos e enquadrar certos modos de ser como o padrão, os danos representacionais fabricam as justificativas infundadas para práticas

opressivas.

Com o conceito de danos representacionais, somos capazes de identificar as associações de palavras enviesadas por gênero como discriminatórias, ainda que elas próprias não sejam um exemplo de distribuição de recursos no sentido dos danos alocativos.

Como o viés surge?

“Todo dado é dado histórico: produto de um tempo, de um lugar, de um clima político, econômico, técnico e social. Se você não está considerando por que seus dados existem, e por que outros conjuntos de dados não existem, você está fazendo ciência de dados errado.”

Melissa Terras (2019)

TRÊS SENTIDOS DE "VIÉS"

Na **estatística**: discrepância entre a estatística de uma amostra e a estatística verdadeira da população.

Na **ciência cognitiva**: um modo de raciocínio que provavelmente produz resultado incorreto ou distorcido.

Na **justiça social**: uma discrepância moralmente suspeita no tratamento de pessoas.

Até aqui conseguimos encontrar uma definição razoável de discriminação e temos ao menos dois exemplos concretos de sistemas de IA participando dela. Em ambos, a prática discriminatória decorre de vieses no próprio sistema. Portanto, se quisermos lidar com a questão, temos algumas perguntas a responder. Como sistemas de IA se tornam enviesados? Como podemos medir se um sistema é enviesado? Como podemos corrigi-lo?

Nesta seção, veremos como práticas discriminatórias se retroalimentam. Ou seja, uma IA enviesada não é apenas uma questão técnica, mas resultado de uma história de práticas sociais. Podemos detectar quando nossos sistemas amplificam essas tendências discriminatórias e, melhor ainda, como podemos interromper o ciclo? Veremos três maneiras pelas quais o viés entra num sistema:

1) Amostra não representativa O modo mais evidente pelo qual o viés entra num sistema é por um conjunto de dados não representativo. Ou seja, os dados que alimentam o sistema de aprendizado não são um retrato fiel do mundo em geral. Não surpreende que, ao manipular o modo como o aprendiz vê o mundo — amplificando algumas instâncias de fenômenos e suprimindo outras —, o sistema aprenda um modelo distorcido.

Por exemplo, a capacidade de reconhecer pessoas é distribuída desigualmente entre grupos étnicos em muitos sistemas de reconhecimento facial. O resultado é que o sistema de classificação de imagens do Google, por exemplo, chegou a rotular pessoas negras como gorilas (Kasperkevic, 2015).

Uma razão para isso, segundo Buolamwini e Gebu (2018), é que muitos conjuntos de dados populares de rostos têm distribuição muito pobre de exemplos entre diferentes gêneros e etnias. Ou seja, a visão dos rostos do mundo fornecida aos sistemas de aprendizado é inequivocamente branca e masculina, e muito pouco representativa da verdadeira distribuição de rostos no mundo. Às vezes

isso é tecnicamente chamado de disparidade de tamanho amostral, e leva a sistemas enviesados porque o algoritmo de aprendizado despreza subpopulações mal representadas para alcançar maior capacidade preditiva sobre a maioria do conjunto de dados.

2) Viés de rótulo “Deixe os dados falarem por si”, diz o ditado. É um bom pensamento, mas a verdade infeliz é que os dados não têm voz própria. Os dados só falam por meio de nossas interpretações — e com frequência essas interpretações são difíceis de fazer. Isso é especialmente verdadeiro em situações em que há discrepância entre o que está sendo medido e o que está sendo investigado.

Por exemplo, prever crimes é uma tarefa que, se bem-feita, interessaria a tribunais, polícias e cidadãos igualmente. Infelizmente, crime é algo difícil de medir e, portanto, bons conjuntos de dados são difíceis de produzir. O que conseguimos medir são coisas a que temos acesso informacional, como prisões e condenações. A esperança é que esses substitutos (*proxies*) se correlacionem bem com a quantidade de crime numa população. Além disso, deveríamos desejar que se correlacionem igualmente bem entre grupos socialmente salientes dentro dela.

A verdade infeliz é que prisões dificilmente são um substituto neutro para crime. Podem dar boa noção do crime geral numa população, mas não se generalizam bem entre agrupamentos. Nos Estados Unidos, pessoas negras podem ter probabilidade muito maior de serem presas por acusações relacionadas a drogas do que pessoas brancas (Ferrer & Connolly, 2018), por exemplo. Isso não significa que pessoas negras tenham mais probabilidade de cometer crimes de drogas, apenas que têm mais probabilidade de serem flagradas, presas e registradas fazendo isso. Assim, quaisquer inferências sobre crime a partir desses dados necessariamente repetirão e reforçarão as injustiças que produziram os próprios dados.

3) Desconhecimento cultural Embora “IA” e “aprendizado de máquina” (*machine learning*) evoquem uma imagem de autonomia maquínica, na realidade grande quantidade de trabalho — trabalho humano — é necessária para tornar sistemas de IA reais. Assim, o comportamento de sistemas de IA não pode ser compreendido olhando apenas para o algoritmo e para os dados que entram nele. Escolhas são feitas no trabalho de implantação, interpretação, projeto e manutenção envolvido na IA, e às vezes essas escolhas criam vieses no sistema.

Um dos exemplos mais claros disso está nos modos pelos quais os dados são “limpos”, envolvendo decisões sobre o que é sinal real em oposição a ruído incômodo. Essa é uma tarefa por vezes vista como faxina e, portanto, como algo que não faz parte do núcleo do negócio da IA — e acontece despercebida em muitas etapas do processo. Por exemplo, ao coletar dados em formulários web, chama-se sanitização de entrada.

O PROBLEMA DOS NOMES

Um bom exemplo é a coleta de nomes. Para impedir que dados falsos entrem no sistema, criam-se certas restrições sobre como os nomes devem ser. Por exemplo, às vezes se supõe que nomes consistem em prenomes e um sobrenome. Às vezes se supõe que nomes contêm apenas letras de A a Z. Às vezes se supõe que nomes sempre têm mais de duas letras.

Essas podem ser suposições razoáveis no contexto cultural limitado dos projetistas e programadores, mas na realidade os nomes são extremamente diversos. Nenhuma forma universal

de nome pode realmente ser dada e, se alguém quiser ser verdadeiramente inclusivo, todos os campos de nome em formulários web deveriam ser caixas de texto de comprimento arbitrário que aceitem qualquer tipo de caractere. Sem compreensão cultural diversa, o sistema pode ser projetado, sem intenção, de modo a deixar de fora grandes grupos de pessoas que não se enquadram nos padrões culturais dominantes.

O viés pode, portanto, entrar num sistema de muitas maneiras diferentes, e as acima são apenas alguns exemplos dos mecanismos em jogo. O ponto importante aqui é que, ao analisar sistemas de IA em busca de injustiça, não basta olhar para os algoritmos. A injustiça pode surgir por razões históricas, culturais, de projeto, de gestão de dados ou de implantação — e, portanto, todo o processo de desenvolvimento de IA deve estar sob escrutínio.

IV. Removendo o viés

Como, então, tornamos sistemas de IA mais justos e menos enviesados? Não há panaceia para o viés — em parte por causa das muitas formas pelas quais ele pode se manifestar, em parte porque não existe uma definição única de resultado algorítmicamente justo. Ainda assim, podemos examinar algumas das situações acima e pensar em como os problemas de justiça poderiam potencialmente ter sido tratados.

Começando pelo exemplo do algoritmo sexista de recrutamento, podemos localizar a origem do viés nas práticas históricas de recrutamento que produziram os dados de treinamento, e na suposição de que práticas passadas fornecem base normativa para práticas futuras (isto é: “devemos contratar esta pessoa porque já contratamos pessoas como ela antes”). Vemos que as questões de fundo estão inextricavelmente ligadas à cultura da empresa e até à cultura de trabalho mais ampla do setor de tecnologia, bem como a um raciocínio moralmente suspeito (lembre-se da guilhotina de Hume, no capítulo 1). São problemas que exigem grandes deslocamentos culturais e reformas estruturais, e é improvável que sejam resolvidos por soluções tecnológicas.

Anticlassificação Ainda assim, poder-se-ia tentar salvar o que for possível do conjunto de dados e ver se ele poderia ficar ao menos menos enviesado. Um conserto técnico comum sobre o conjunto de dados chama-se anticlassificação, ou remoção explícita das variáveis protegidas. Isso significa apagar informações como gênero ou etnia, e seus substitutos, dos dados. Aqui, substitutos são características fortemente correlacionadas com as características protegidas. Como no caso do algoritmo de recrutamento mencionado antes, se o currículo de uma pessoa contém referências a licença-maternidade ou a uma faculdade feminina, o algoritmo ainda poderia fazer previsões marcadas por gênero mesmo que a variável explícita de gênero seja omitida.

Isso pode contribuir em certa medida para reduzir o viés no sistema, mas se é eficaz em algum cenário específico precisa ser verificado por testes e auditoria. Corbett-Davies e Goel (2018) mostraram que a anticlassificação pode até ser prejudicial à justiça em certas situações, nas quais características têm poder preditivo diferente entre grupos sociais. Uma ilustração são os sintomas de infarto: pesquisas mostraram que infartos se apresentam de modo muito diferente em pacientes mulheres e homens. Os sintomas que a maioria sabe procurar, por exemplo dor torácica do lado direito, são muito mais comuns em pacientes homens do que mulheres. Assim, um aplicativo em que se pudesse verificar

“estou tendo um infarto?” provavelmente daria resultados muito errados se não levasse em conta o sexo do paciente.

Reamostragem Em casos como o do algoritmo de reconhecimento facial pesquisado por Buolamwini e Gebru, em que o viés é produzido por disparidade de tamanho amostral, a reamostragem é uma forma possível de abordar o problema. Isso pode significar usar apenas uma porção menor do conjunto de dados, que tenha melhor distribuição de exemplos entre todos os agrupamentos sociais relevantes. Outra forma de reamostrar é produzir exemplos sintéticos dos grupos sub-representados (Chawla et al., 2002). Novamente, se isso funciona é questão de verificação caso a caso. Pode ser que o conjunto de dados esteja tão desequilibrado que não haja como corrigi-lo, a não ser criando um novo do zero. Além disso, num caso tão sensível e de alto risco como o reconhecimento facial, não é dado que o sistema será ético, justo e não discriminatório mesmo que a classificação seja não enviesada e o conjunto de dados igualmente representativo. Abordaremos isso na próxima seção mas, em termos de tornar a IA justa, às vezes a única maneira de fazê-lo é não desenvolver aquela IA em primeiro lugar.

Discriminação para além do viés O importante a lembrar aqui é que discriminação não é o mesmo que viés sistemático. O viés em sistemas de IA é causa bastante evidente de práticas discriminatórias e, por sua natureza quantificável, encaixa-se facilmente no mundo conceitual da pesquisa técnica em IA. Talvez seja por isso que o salto conceitual da discriminação para o viés seja feito com tanta frequência.

Ainda assim, sistemas de IA podem participar de práticas discriminatórias que não decorrem de viés no próprio sistema. Precisamos, antes, expandir nosso objeto de investigação das minúcias do modelo de IA para todo o sistema de instituições do qual ele participa.

QUANDO O PROBLEMA NÃO É A ACURÁCIA

No início de 2018, pesquisadores da Stanford Graduate School of Business publicaram um artigo detalhando um sistema de aprendizado profundo (*deep learning*) capaz de distinguir entre homens gays e heterossexuais com acurácia de 81% a partir de uma única foto do rosto. Os achados foram controversos, no mínimo, e por muitas razões diferentes. Críticos levantaram preocupações sobre a ressurreição da pseudociência da fisionomia, que tem conexão profundamente enraizada com injustiças racistas históricas. Houve também suspeitas de que o sistema, em vez de captar sutis marcadores genéticos como se alegava, na verdade estivesse rastreando o modo como as pessoas tendem a se arrumar e a tirar fotos de si mesmas. Além disso, esse sistema de IA opera claramente numa área eticamente nebulosa quanto a privacidade, autodeterminação e, evidentemente, discriminação. Deixando de lado as outras preocupações por ora, como a discriminação funciona aqui? Claramente o viés de classificação não é o elemento discriminatório: não é eticamente relevante para nós se o estimador é mais acurado em prever homossexualidade em alguns grupos do que em outros. A característica eticamente relevante do sistema é que, independentemente de sua acurácia, ele possibilita diretamente tratamento diferenciado com base em agrupamento social percebido.

Não é preciso detalhar exemplos de usos maliciosos de sistemas como o descrito acima, pois sua possi-

bilidade deve ser óbvia a todos. Deixando de lado os usos diretamente maliciosos, podemos imaginar a integração de tal tecnologia, por exemplo, à maquinaria de publicidade personalizada online composta por redes sociais, processadores de dados, influenciadores de tendências e comerciantes globais. Mesmo que a IA classificadora seja, por todos os padrões técnicos, justa e não enviesada, ela condiciona a publicidade online de bens ao princípio discriminatório de que a orientação sexual presumida é razão válida para tratar pessoas de modo diferente.

Isso nos leva a um ponto importante para quem considera a ética dos sistemas de IA: cuidado com a armadilha do reducionismo! Ou seja, devemos evitar reduzir o conceito de ética a valores simplificados, quantificados e de atalho, como “ausência de viés”. Como sistemas de IA participam de processos muito mais complexos do que aquilo que o próprio sistema faz, a ética não pode ser medida apenas olhando os valores de entrada e de saída do algoritmo.

Em suma: **justo não significa ético.**

EXERCÍCIOS DESTA SEÇÃO

O material original traz aqui dois questionários interativos. As perguntas não constam do repositório de origem — ficam no banco de dados da plataforma. Os exercícios correspondentes devem ser redigidos em exercicios/capitulo06-exercicios.md.

Referências

- Bolukbasi, T., Chang, K.-W., Zou, J., Saligrama, V., & Kalai, A. (2016). Man is to Computer Programmer as Woman is to Homemaker? Debiasing Word Embeddings. <https://arxiv.org/abs/1607.06520>
- Buolamwini, J., & Gebru, T. (2018). Gender Shades: Intersectional Accuracy Disparities in Commercial Gender Classification. *PMLR* 81. <http://proceedings.mlr.press/v81/buolamwini18a/buolamwini18a.pdf>
- Chawla, N. V., et al. (2002). SMOTE: Synthetic Minority Over-sampling Technique.
- Corbett-Davies, S., & Goel, S. (2018). The Measure and Mismeasure of Fairness.
- Crawford, K. (2017). The Trouble with Bias. *NIPS 2017 Keynote*.
- Dastin, J. (2018). Amazon scraps secret AI recruiting tool that showed bias against women. *Reuters*.
- Ferrer, B., & Connolly, J. M. (2018). Racial Inequities in Drug Arrests.
- Kasperkevic, J. (2015). Google says sorry for racist auto-tag in photo app. *The Guardian*.
- Lippert-Rasmussen, K. (2014). *Born Free and Equal?* Oxford University Press.
- Rawls, J. (1971). *A Theory of Justice*. Harvard University Press.
- Rutkenstein, M., & Velkova, J. (2019). Automating Society: Finland. *AlgorithmWatch*.
- Terras, M. (2019). Palestra. <https://www.youtube.com/watch?v=4yYtLUViI4>
- Wilson, B., Hoffman, J., & Morgenstern, J. (2019). Predictive Inequity in Object Detection. <http://arxiv.org/abs/1902.11097>

Material original: *Ethics of AI*, um curso online gratuito da Universidade de Helsinque. Professores responsáveis: Anna-Mari Rusanen e Jukka K. Nurminen. Demais contribuintes principais: Santeri Räisänen, Sasu Tarkoma e Saara Halmetoja. Disponível em <https://ethics-of-ai.mooc.fi/>.

Esta versão: tradução e adaptação para o português brasileiro realizada por José Lucas Lira Bizil, Fernando Mazzeto Lisboa Lima e Matheus da Silva Fernandes, no âmbito do Programa CiberExt 26-29 (FEELT38103), Universidade Federal de Uberlândia, 2026. Esta é uma obra derivada; os autores originais não a revisaram nem a endossam.

Licença: Creative Commons Atribuição-NãoComercial-Compartilhual 4.0 Internacional (CC BY-NC-SA 4.0) — <https://creativecommons.org/licenses/by-nc-sa/4.0/deed.pt-br>.